

Multi-Modal Classification

of Images and Text using Deep Learning

Dataset : Flickr8k

8 091

Images

5

Captions / image

6

Classes

Plan de la présentation

Step 1

Image Processing with CNN

ResNet50 pré-entraîné

Vecteurs 2048-d

Transfer learning

Step 2

Text Processing with RNN

GloVe + BiLSTM

Vecteurs 512-d

97.1% couverture GloVe

Step 3

Multi-Modal Fusion

Concat 2048+512=2560-d

FC layers + Softmax

90.12% accuracy

Step 4

Tuning & Optimization

Random Search · Early Stop

Meilleure config trouvée

98.02% accuracy

Dataset — Flickr8k

Flickr8k

8 091 images photographiques variées

5 captions par image en anglais

40 455 couples image-texte au total

6 classes générées par mots-clés :

dog

chiens

child

enfants

water

eau / plage

sport

activités

outdoor

nature

other

autres

Distribution des classes

child

2517

other

2156

dog

1928

sport

808

water

343

outdoor

339

Pipeline

01 Chargement des données

8 091 images · 40 455 captions

02 Prétraitement

Resize 224x224 · Normalisation ImageNet

03 ResNet50 sans couche FC

Extraction de features visuelles

04 Vecteur 2048-d par image

Sauvegardé dans image_features_resnet50.npy

Architecture ResNet50

Image (3 x 224 x 224)

- > Conv Block 1 (64 filtres)
- > Conv Block 2 (128 filtres)
- > Conv Block 3 (256 filtres)
- > Conv Block 4 (512 filtres)
- > Average Pooling

-> [FC supprimée]

Feature vector (2048-d)

Resultats Step 1

8 091 images traitées avec succes

Vecteurs 2048-d extraits et sauvegardes

Temps : ~8 min 47 s (CPU)

Normalisation ImageNet

mean = [0.485, 0.456, 0.406]

std = [0.229, 0.224, 0.225]

GloVe Embeddings (200-d)

Pre-entraîne sur des milliards de mots (Wikipedia + Common Crawl)

5 039 / 5 191 mots trouvés dans GloVe (97.1%)

Mots inconnus : initialisation aléatoire ($N(0, 0.6)$)

Embeddings affines pendant l'entraînement

Vecteur nul pour le token <pad>

BiLSTM — Architecture

Caption → Embedding (200-d)

→ LSTM forward → h_T (256-d)

→ LSTM backward → h_T (256-d)

→ **Concatenation** → **t (512-d)**

Avantage : capture le contexte
dans les deux sens de la séquence

Formulation mathématique

[Embedding]

$e_t = \text{Embed}(w_t)$ élément de $\mathbb{R}^{200}$

[LSTM bidirectionnel]

$h_{\rightarrow T}, h_{\leftarrow T} = \text{BiLSTM}(e_1, \dots, e_T)$

[Représentation finale]


$t = [h_{\rightarrow T} \parallel h_{\leftarrow T}]$ élément de $\mathbb{R}^{512}$

Paramètres

Embed dim	200-d (GloVe)
Hidden dim	256-d
BiLSTM output	512-d
Vocab size	5 191
MIN_FREQ	2
Dropout	0.3

Step 3 — Multi-Modal Fusion

2048 + 512 = 2560-d



Hyperparametres	
VISUAL_DIM	2048-d
TEXT_DIM	512-d
FUSED_DIM	2560-d
FC_HIDDEN	[1024, 512]
DROPOUT	0.4
NUM_EPOCHS	30
LR	1e-4

Optimisation
Optimizer : AdamW
Scheduler : CosineAnnealingLR
Loss : CrossEntropy ponderee (corrige le desequilibre des classes)
BatchNorm + Dropout + Xavier init
Split 70 / 15 / 15 stratifie

Resultat Step 3
90.12%
Test Accuracy
1 214 samples de test
6 classes de classification
30 epochs d'entrainement

Step 4 — Model Tuning & Optimization

98.02% final

Early Stopping

patience = 7

-> Surveille la val loss a chaque epoch

-> Sauvegarde les meilleurs poids

-> Stoppe si pas d'amelioration

-> sur 7 epochs consecutives

-> Evite l'overfitting (gap train/val)

Random Search

9 configurations testees

-> dropout : [0.3, 0.4, 0.5]

-> LR : [5e-4, 1e-4, 5e-5]

-> FC : [512,256] / [1024,512] / [512]

-> 10 epochs rapides par config

-> Selection par meilleure val accuracy

Loss ponderee

CrossEntropyLoss

-> Poids = 1 / frequence de classe

-> Classes rares = poids plus eleve



-> water et outdoor favorises

-> Corrige le desequilibre inherent

-> au dataset Flickr8k

Meilleure config : dropout=0.3 | LR=5e-4 | FC=[512, 256]

Resultats — Comparaison des modeles



Performance par classe — Modele optimise (F1-score) :

child

1.00

dog

1.00

other

0.97

outdoor

0.91

sport

0.96

water

0.93


24

erreurs sur 1 214 samples

Taux d'erreur : 2.0%

Causes principales

- > Classes ambiguës : enfant jouant au sport (child vs sport)
- > Contextes mixtes : chien à la plage (dog vs water)
- > Classes rares sous-représentées : outdoor, water
- > Caption non représentative de la scène principale



ResNet50

Encodeur visuel

- > 50 couches vs VGG16 (138M params) : plus léger et plus précis
- > Connexions résiduelles : évitent la dégradation du gradient en profondeur
- > Pré-entraîné sur ImageNet (1,2M images) : transfer learning immédiat
- > AvgPool final : vecteur 2048-d compact et riche sémantiquement

GloVe + BiLSTM

Encodeur textuel

- > GloVe vs embeddings aléatoires : 97,1% de couverture, convergence 3x plus rapide
- > BiLSTM vs LSTM simple : capture le contexte dans les deux sens de la caption
- > BiLSTM vs BERT : plus léger, adapté à des captions courtes (< 30 mots)
- > Sortie 512-d : équilibre expressivité et coût mémoire

Concaténation

Stratégie de fusion

- > Concaténation vs attention cross-modale : plus simple, efficace sur Flickr8k
- > Préserve l'intégralité de l'information des deux modalités
- > Les couches FC apprennent les corrélations image–texte
- > Dimension 2560-d : suffisante pour 6 classes sans sur-paramétrage

Ce que chaque modalité apporte seule

CNN seul 70.1%

Reconnaît les formes visuelles
Confond les contextes similaires
Ex : chien vs loup (visuel proche)


BiLSTM seul 95.6%

Capture le sens sémantique
Performant sur Flickr8k (captions
descriptives)
Limité si caption ambiguë

Pourquoi la fusion apporte +27.92% vs CNN seul

- > La caption lève les ambiguïtés visuelles (ex : 'a dog swimming' -> water + dog)
- > L'image confirme la caption quand elle est vague
- > Les deux modalités se complètent sur les classes rares (outdoor, water)
- > **Résultat : 98.02% — meilleur que chaque modalité seule**

Gain cumulatif par rapport au CNN seul



Limites actuelles

Labels par mots-clés

Les 6 classes sont générées automatiquement — pas de ground truth humain. Biais possible si la caption ne décrit pas l'image complètement.

Features statiques

ResNet50 est utilisé en feature extractor figé. Un fine-tuning end-to-end permettrait d'adapter les features à Flickr8k.

Fusion par concat.

La concaténation ne modélise pas explicitement les interactions entre les deux modalités (pas d'attention cross-modale).

Dataset limité

8 091 images : petit dataset. Les performances pourraient être différentes sur un dataset plus diversifié (MS COCO, Visual Genome).

Perspectives

Fine-tuning CNN

Dégeler les derniers blocs de ResNet50 pour adapter les features visuelles à Flickr8k.

Mécanisme d'attention

Remplacer la concaténation par une attention cross-modale pour modéliser explicitement les interactions image–texte.

BERT / CLIP

Utiliser des encodeurs textuels pré-entraînés plus puissants (BERT) ou des modèles multimodaux natifs (CLIP).

Augmentation de données

Data augmentation sur les images (flip, crop, jitter) et les captions (paraphrase) pour réduire l'overfitting.

Conclusion

Pipeline complet

Step 1->2->3->4 : extraction visuelle, encodage textuel, fusion, optimisation

Resultat final

98.02% d'accuracy — seulement 24 erreurs sur 1 214 samples de test

Apport de la fusion

+27.92% vs CNN seul — la combinaison image+texte ameliore drastiquement les performances

Techniques cles

Transfer learning (ResNet50 + GloVe), BiLSTM, Early Stopping, Random Search



Merci !