



École d'ingénieurs du numérique

RAPPORT THÉORIQUE ET MATHÉMATIQUE

Classification Multi-Modale d'Images et de Texte

Cours: IG.2313

Juin 2026

Par Khaleb TCHOUMBOU, Guillaume ORY, Enzo DUVAL

Deep Learning Project | 2025–2026

Table des matières

1. Introduction et contexte.....	3
1.1 Dataset — Flickr8k.....	3
2. Encodeur visuel — ResNet50	3
2.1 Convolution et principe général	3
2.2 Blocs résiduels (Residual Blocks)	4
2.3 Extraction de features et prétraitement.....	4
3. Encodeur textuel — GloVe et BiLSTM	4
3.1 Prétraitement des captions.....	4
3.2 Embeddings GloVe (Global Vectors for Word Representation)	5
3.3 LSTM Bidirectionnel (BiLSTM).....	5
3.3.1 Équations du LSTM	5
3.3.2 Bidirectionnalité	5
4. Module de fusion multi-modale.....	6
4.1 Principe de la concaténation.....	6
4.2 Couches Fully Connected et classification.....	6
4.3 Fonction de perte pondérée	6
5. Entraînement et optimisation.....	7
5.1 Optimiseur — AdamW	7
5.2 Scheduler — CosineAnnealingLR.....	7
5.3 Régularisation — Dropout et BatchNorm.....	7
5.4 Early Stopping	8
5.5 Random Search des hyperparamètres.....	8
6. Architecture complète du modèle optimal	8
7. Résultats expérimentaux.....	9
7.1 Comparaison des modèles.....	9
7.2 Performance par classe — modèle optimal.....	9
7.3 Analyse des erreurs.....	9
8. Conclusion	10

1. Introduction et contexte

Ce rapport présente la description théorique et mathématique complète du modèle optimal développé dans le cadre du projet de classification multi-modale sur le dataset Flickr8k.

L'objectif est de classifier des paires image–texte en 6 catégories thématiques (dog, child, water, sport, outdoor, other) en combinant deux flux d'information complémentaires : la vision par ordinateur et le traitement du langage naturel.

L'approche retenue s'appuie sur trois composants principaux :

- Un encodeur visuel basé sur ResNet50 pré-entraîné (transfer learning).
- Un encodeur textuel basé sur des embeddings GloVe et un BiLSTM.
- Un module de fusion par concaténation suivi de couches fully connected.

1.1 Dataset — Flickr8k

Flickr8k est un dataset standard en vision-langage composé de 8 091 images photographiques, chacune annotée par 5 captions en anglais, soit 40 455 couples image–texte. Les labels de classification sont générés automatiquement par détection de mots-clés dans les captions.

Statistiques du dataset

Images uniques	: 8 091
Captions par image	: 5
Total couples	: 40 455
Vocabulaire	: 5 191 mots (MIN_FREQ = 2)
Split	: 70% train / 15% val / 15% test (stratifié)
Classes	: dog, child, water, sport, outdoor, other

2. Encodeur visuel — ResNet50

2.1 Convolution et principe général

ResNet50 est un réseau de neurones convolutif profond pré-entraîné sur ImageNet (1,2 million d'images, 1 000 classes). Une convolution 2D applique un filtre w de taille $(k \times k)$ sur une image d'entrée x :

$$(x * w)[i, j] = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} x[i+m, j+n] * w[m, n]$$

où $*$ désigne l'opération de convolution. La sortie de chaque couche de convolution est suivie d'une normalisation par batch (Batch Normalization) et d'une activation ReLU :

$$\begin{aligned} \text{BN}(z) &= \gamma * (z - \mu_B) / \sqrt{\sigma_B^2 + \epsilon} + \beta \\ \text{ReLU}(z) &= \max(0, z) \end{aligned}$$

où μ_B et σ_B^2 sont la moyenne et la variance du mini-batch, γ et β sont des paramètres appris, et ϵ est un terme de stabilité numérique.

2.2 Blocs résiduels (Residual Blocks)

L'innovation centrale de ResNet est la connexion résiduelle (skip connection) qui permet au gradient de se propager directement à travers les couches sans dégradation. Pour un bloc résiduel, la sortie est :

$$\begin{aligned} F(x) &= H(x) - x \\ y &= F(x, \{W_i\}) + x \end{aligned}$$

où $H(x)$ est la fonction désirée et $F(x, \{W_i\})$ est le résidu appris. Si la dimension de x change (downsampling), une projection linéaire W_s est appliquée :

$$y = F(x, \{W_i\}) + W_s * x$$

ResNet50 comporte 4 blocs résiduels avec respectivement 64, 128, 256 et 512 filtres, soit 50 couches paramétrées au total.

2.3 Extraction de features et prétraitement

Les images sont prétraitées selon le standard ImageNet avant d'être passées dans le réseau :

- Redimensionnement à 224 x 224 pixels.
- Conversion en tenseur (valeurs dans [0, 1]).
- Normalisation channel par channel :

$$\begin{aligned} x_{\text{norm}}[c] &= (x[c] - \mu[c]) / \sigma[c] \\ \mu &= [0.485, 0.456, 0.406] \quad (\text{RGB}) \\ \sigma &= [0.229, 0.224, 0.225] \quad (\text{RGB}) \end{aligned}$$

La couche de classification finale (Fully Connected, 2048 -> 1000) est supprimée. La sortie de la couche Average Pooling constitue le vecteur de features visuelles :

$$v = \text{AvgPool}(\text{ResNet50_conv}(x_{\text{img}})) \quad \text{element de } \mathbb{R}^{\{2048\}}$$

Ce vecteur de 2 048 dimensions encode le contenu sémantique de l'image (objets, scènes, textures) sans présupposer une classe particulière. Les features de 8 091 images sont pré-extraites et sauvegardées, ce qui évite de recalculer ResNet50 à chaque epoch d'entraînement.

3. Encodeur textuel — GloVe et BiLSTM

3.1 Prétraitement des captions

Chaque caption subit les transformations suivantes avant encodage :

- Passage en minuscules.
- Suppression de la ponctuation et des caractères numériques.
- Tokenisation : découpage en séquence de mots.
- Filtrage du vocabulaire : seuls les mots apparaissant au moins 2 fois sont conservés.

Deux tokens spéciaux sont définis : <pad> (indice 0) pour le padding des séquences, et <unk> (indice 1) pour les mots hors vocabulaire.

3.2 Embeddings GloVe (Global Vectors for Word Representation)

GloVe (Pennington et al., 2014) est un modèle d'embedding pré-entraîné qui apprend des vecteurs denses à partir des co-occurrences de mots dans un grand corpus. L'objectif d'entraînement de GloVe est :

$$J = \sum_{i,j=1}^V f(X_{ij}) * (w_i^T * w_j + b_i + b_j - \log X_{ij})^2$$

où X_{ij} est le nombre de co-occurrences des mots i et j , w_i et w_j sont leurs vecteurs d'embedding, b_i et b_j sont des biais scalaires, et f est une fonction de pondération qui réduit l'influence des paires très fréquentes.

Nous utilisons GloVe pré-entraîné sur Common Crawl avec des vecteurs de dimension 200. 97,1% des mots du vocabulaire Flickr8k sont trouvés dans GloVe (5 039 / 5 191). Les mots restants sont initialisés aléatoirement avec $N(0, 0.6^2)$. Le vecteur <pad> est fixé à zéro.

La matrice d'embedding E de dimension $(|V| \times 200)$ est initialisée avec les vecteurs GloVe, puis affinée (fine-tuning) pendant l'entraînement :

$$e_t = E[w_t] \quad \text{element de } \mathbb{R}^{200}$$

où w_t est l'indice du t -ième mot de la caption.

3.3 LSTM Bidirectionnel (BiLSTM)

3.3.1 Équations du LSTM

Le Long Short-Term Memory (Hochreiter & Schmidhuber, 1997) est une architecture récurrente qui capture les dépendances à longue distance grâce à des portes (gates) contrôlant le flux d'information. À chaque pas de temps t , le LSTM calcule :

$$\begin{aligned} f_t &= \sigma(W_f * [h_{t-1}, e_t] + b_f) && \text{[porte d'oubli]} \\ i_t &= \sigma(W_i * [h_{t-1}, e_t] + b_i) && \text{[porte d'entree]} \\ g_t &= \tanh(W_g * [h_{t-1}, e_t] + b_g) && \text{[cellule candidate]} \\ o_t &= \sigma(W_o * [h_{t-1}, e_t] + b_o) && \text{[porte de sortie]} \\ c_t &= f_t \odot c_{t-1} + i_t \odot g_t && \text{[etat de cellule]} \\ h_t &= o_t \odot \tanh(c_t) && \text{[etat cache]} \end{aligned}$$

où σ est la fonction sigmoïde, $\tanh$ est la tangente hyperbolique, $\odot$ est le produit élément par élément (Hadamard), et $W_f, W_i, W_g, W_o, b_f, b_i, b_g, b_o$ sont les paramètres appris.

3.3.2 Bidirectionnalité

Un BiLSTM exécute deux LSTM en parallèle : un dans le sens direct (forward) et un dans le sens inverse (backward). Cela permet de capturer le contexte gauche et droit de chaque mot :

$$\begin{aligned} h_T^{\text{forward}} &= \text{LSTM_forward}(e_1, e_2, \dots, e_T) \\ h_1^{\text{backward}} &= \text{LSTM_backward}(e_T, e_{T-1}, \dots, e_1) \end{aligned}$$

La représentation finale de la caption est obtenue par concaténation des deux états cachés finaux :

$$t = [h_T^{\text{forward}} \parallel h_1^{\text{backward}}] \quad \text{element de } \mathbb{R}^{\{512\}}$$

avec h_T^{forward} et h_1^{backward} chacun de dimension 256 (HIDDEN_DIM), ce qui donne un vecteur textuel de dimension 512.

4. Module de fusion multi-modale

4.1 Principe de la concaténation

La fusion par concaténation est l'approche la plus directe pour combiner deux modalités. Elle consiste à juxtaposer les vecteurs de features des deux encodeurs pour former un vecteur de représentation joint :

$$\begin{aligned} v & \text{ element de } \mathbb{R}^{\{2048\}} && [\text{features visuelles} - \text{ResNet50}] \\ t & \text{ element de } \mathbb{R}^{\{512\}} && [\text{features textuelles} - \text{BiLSTM}] \\ z & = [v \parallel t] \quad \text{element de } \mathbb{R}^{\{2560\}} && [\text{vecteur fusionne}] \end{aligned}$$

L'avantage de cette approche est sa simplicité et son efficacité computationnelle. Les couches FC suivantes apprennent les interactions entre les deux modalités.

4.2 Couches Fully Connected et classification

Le vecteur fusionné z est passé à travers deux couches fully connected avec normalisation par batch (BatchNorm), activation ReLU et Dropout :

$$\begin{aligned} h_1 & = \text{ReLU}(\text{BN}(W_1 * z + b_1)) && h_1 \text{ element de } \mathbb{R}^{\{1024\}} \\ & h_1 = \text{Dropout}(h_1, p=0.4) \\ h_2 & = \text{ReLU}(\text{BN}(W_2 * h_1 + b_2)) && h_2 \text{ element de } \mathbb{R}^{\{512\}} \\ & h_2 = \text{Dropout}(h_2, p=0.4) \\ \text{logits} & = W_3 * h_2 + b_3 && \text{logits element de } \mathbb{R}^{\{6\}} \end{aligned}$$

La prédiction finale est obtenue par la fonction Softmax :

$$y_{\text{hat}}[k] = \frac{\exp(\text{logits}[k])}{\sum_{j=1}^6 \exp(\text{logits}[j])}$$

La classe prédite est l'argmax des probabilités : $c^* = \text{argmax}_k y_{\text{hat}}[k]$. Les paramètres W_1 , W_2 , W_3 et b_1 , b_2 , b_3 sont initialisés par la méthode de Xavier (Glorot & Bengio, 2010) pour assurer une distribution stable des activations en début d'entraînement.

4.3 Fonction de perte pondérée

Le dataset Flickr8k présente un déséquilibre entre les classes (child: 2517 vs water: 343). Pour corriger ce biais, nous utilisons la Cross-Entropy Loss pondérée :

$$L = - \sum_{k=1}^6 w_k * y_k * \log(y_{\text{hat}}_k)$$

où y_k est le label one-hot de la classe k , y_{hat}_k est la probabilité prédite pour la classe k , et w_k est le poids de la classe k défini comme :

$$w_k = (1 / N_k) / \sum_{j=1}^6 (1 / N_j) \quad * \quad 6$$

avec N_k le nombre de samples de la classe k dans l'ensemble d'entraînement. Cela attribue un poids plus élevé aux classes rares (water, outdoor) et réduit l'influence des classes dominantes (child, other).

5. Entraînement et optimisation

5.1 Optimiseur — AdamW

Nous utilisons l'optimiseur AdamW (Loshchilov & Hutter, 2019), une variante d'Adam qui découple la régularisation L2 de la mise à jour des gradients. La mise à jour des paramètres θ à l'itération t est :

$$\begin{aligned} g_t &= \text{gradient}_{\theta} L_t(\theta) \\ m_t &= \beta_1 * m_{t-1} + (1 - \beta_1) * g_t \\ v_t &= \beta_2 * v_{t-1} + (1 - \beta_2) * g_t^2 \\ m_{\text{hat}}_t &= m_t / (1 - \beta_1^t) \\ v_{\text{hat}}_t &= v_t / (1 - \beta_2^t) \\ \theta_t &= \theta_{t-1} - lr * m_{\text{hat}}_t / (\sqrt{v_{\text{hat}}_t} + \epsilon) - lr * \lambda * \theta_{t-1} \end{aligned}$$

où $\beta_1 = 0.9$ et $\beta_2 = 0.999$ sont les coefficients de moment, $\epsilon = 1e-8$ est un terme de stabilité, et $\lambda = 1e-4$ est le coefficient de décroissance des poids (weight decay). Le learning rate utilisé est $lr = 5e-4$ (meilleure configuration trouvée par Random Search).

5.2 Scheduler — CosineAnnealingLR

Le learning rate est réduit progressivement selon un cosinus pour permettre une convergence fine en fin d'entraînement :

$$lr_t = lr_{\min} + 0.5 * (lr_{\max} - lr_{\min}) * (1 + \cos(\pi * t / T_{\max}))$$

avec $T_{\max} = 50$ epochs, $lr_{\min} = 1e-6$, et $lr_{\max} = 5e-4$.

5.3 Régularisation — Dropout et BatchNorm

Le Dropout (Srivastava et al., 2014) désactive aléatoirement une fraction $p = 0,4$ des neurones à chaque forward pass pendant l'entraînement, forçant le réseau à apprendre des représentations redondantes :

$$\text{Dropout}(h, p) = h \odot m / (1 - p) \quad \text{avec} \quad m_i \sim \text{Bernoulli}(1 - p)$$

La Batch Normalization (Ioffe & Szegedy, 2015) normalise les activations de chaque couche pour accélérer la convergence et réduire la sensibilité à l'initialisation des poids.

5.4 Early Stopping

L'Early Stopping interrompt l'entraînement lorsque la val loss ne s'améliore pas de plus de $\delta = 1e-4$ pendant $\text{patience} = 7$ epochs consécutives. À chaque amélioration, les poids du modèle sont sauvegardés :

```
Si val_loss_t < best_loss - delta : sauvegarder theta_t,
                                   counter = 0

Sinon                               : counter = counter + 1

Si counter >= patience              : arreter l'entraînement
```

Cette technique prévient l'overfitting (sur-apprentissage) observé dans notre modèle de base après l'epoch 8.

5.5 Random Search des hyperparamètres

Nous avons effectué un Random Search sur l'espace suivant :

Espace de recherche (Random Search)

dropout : {0.3, 0.4, 0.5}
LR : {5e-4, 1e-4, 5e-5}
FC hidden : {[512, 256], [1024, 512], [512]}
Configurations testées : 9 (10 epochs rapides chacune)
Meilleure config : dropout=0.3, LR=5e-4, FC=[512, 256]

6. Architecture complète du modèle optimal

Le pipeline complet peut être résumé ainsi :

```
Image --> ResNet50_conv(.) --> AvgPool --> v (2048-d)
Caption --> GloVe_Embed(.) --> BiLSTM --> t (512-d)
z      = [v || t] (2560-d)
h_1    = Dropout(ReLU(BN(W_1 * z + b_1))) (1024-d)
h_2    = Dropout(ReLU(BN(W_2 * h_1 + b_2))) (512-d)
y_hat  = Softmax(W_3 * h_2 + b_3) (6-d)
```

Paramètres du modèle optimal

Encodeur visuel : ResNet50 pré-entraîné (features statiques, 2048-d)
Encodeur textuel : GloVe(200-d) + BiLSTM(256-d x 2 = 512-d)
Dimension fusionnée: 2048 + 512 = 2 560-d
Couches FC : [2560 -> 1024 -> 512 -> 6]
Dropout : $p = 0.3$
BatchNorm : après chaque couche FC (sauf la dernière)

Initialisation	: Xavier uniform pour les poids FC
Paramètres entraî.	: 17 238 150
Optimiseur	: AdamW (lr=5e-4, weight_decay=1e-4)
Scheduler	: CosineAnnealingLR (T_max=50, eta_min=1e-6)
Loss	: CrossEntropyLoss pondérée
Early Stopping	: patience=7, delta=1e-4

7. Résultats expérimentaux

7.1 Comparaison des modèles

Les performances des différents modèles sur le jeu de test (1 214 samples) sont :

Modèle	Test Accuracy	Gain vs CNN seul
CNN seul (ResNet50)	70,10%	—
BiLSTM seul (GloVe)	95,63%	+25,53%
Multi-Modal — Step 3	90,12%	+20,02%
Multi-Modal — Tuned (optimal)	98,02%	+27,92%

7.2 Performance par classe — modèle optimal

Le rapport de classification détaillé sur le jeu de test montre une performance très élevée sur toutes les classes :

Classe	Précision	Rappel	F1-score	Support
child	0.99	1.00	1.00	377
dog	1.00	0.99	1.00	290
other	0.97	0.97	0.97	324
outdoor	0.92	0.90	0.91	51
sport	0.97	0.95	0.96	121
water	0.91	0.96	0.93	51

Le modèle obtient un F1-score de 1.00 sur les classes dog et child, et maintient des performances excellentes sur les classes rares (water: 0.93, outdoor: 0.91) grâce à la loss pondérée. Le taux d'erreur global est de 2,0% (24 erreurs sur 1 214 samples).

7.3 Analyse des erreurs

Les 24 erreurs restantes s'expliquent principalement par :

- L'ambiguïté des classes : un enfant jouant au sport peut être classé child ou sport.
- Les contextes mixtes : un chien à la plage active à la fois dog et water.
- La faible représentation de outdoor et water dans le dataset (51 samples chacune en test).
- Des captions non représentatives de la scène principale de l'image.

8. Conclusion

Ce rapport a présenté la description mathématique complète du modèle optimal de classification multi-modale image–texte développé sur Flickr8k. Le pipeline combine trois composants théoriquement fondés :

- ResNet50 avec connexions résiduelles pour l'encodage visuel robuste via transfer learning.
- GloVe + BiLSTM pour l'encodage textuel capturant les dépendances contextuelles dans les deux sens.
- Une fusion par concaténation suivie de couches FC avec régularisation (Dropout, BatchNorm).

Les techniques d'optimisation — loss pondérée pour le déséquilibre des classes, AdamW avec CosineAnnealingLR, et Early Stopping avec Random Search — ont permis d'atteindre une accuracy de 98,02% sur le jeu de test, soit un gain de +27,92% par rapport au CNN seul. Ce résultat valide l'intérêt de la fusion multi-modale pour la classification d'images annotées.

— *Fin du rapport* —